

Quantum HackMx

¡Mejora, transforma e implementa utilizando tu creatividad y el aprendizaje automático para la detección de fraudes bancarios!

Reto Propuesto por NDS Cognitive Labs

Equipo CyberBots
ITESM CEM IRS-ITC, 2do Semestre

Cesar Emiliano Palomé Luna
Paulo Ogando Gúlias
José Luis Madrigal Sánchez
Ana Patricia Islas Mainou



Introducción

Fraudes Bancarios

Los fraudes bancarios han aumentado recientemente debido al aumento de las transacciones; por lo que es imperativo generar algoritmos capaces de detectarlos de manera oportuna para evitar pérdidas monetarias.

Además, es responsabilidad conjunta de las empresas y de los estudiantes el velar por el bienestar de los clientes y los ciudadanos, por lo que realizar este tipo de proyectos es indispensable.

Redes Neuronales para Deep Learning y Data Science

Se decidió programar redes neuronales por su gran capacidad de adaptación durante el entrenamiento y por ser un método con gran tolerancia a los errores.



Algoritmo

Previo a la programación, se realizó un algoritmo con los puntos más importantes que debía contener el programa.

Se utilizó base de datos **Kaggle Credit Card Fraud Detection**, que contiene un total de **284,807** registros dónde **284,315** son transacciones legales y **492** son fraudes bancarios.

Librerías de Python utilizadas:



Pandas



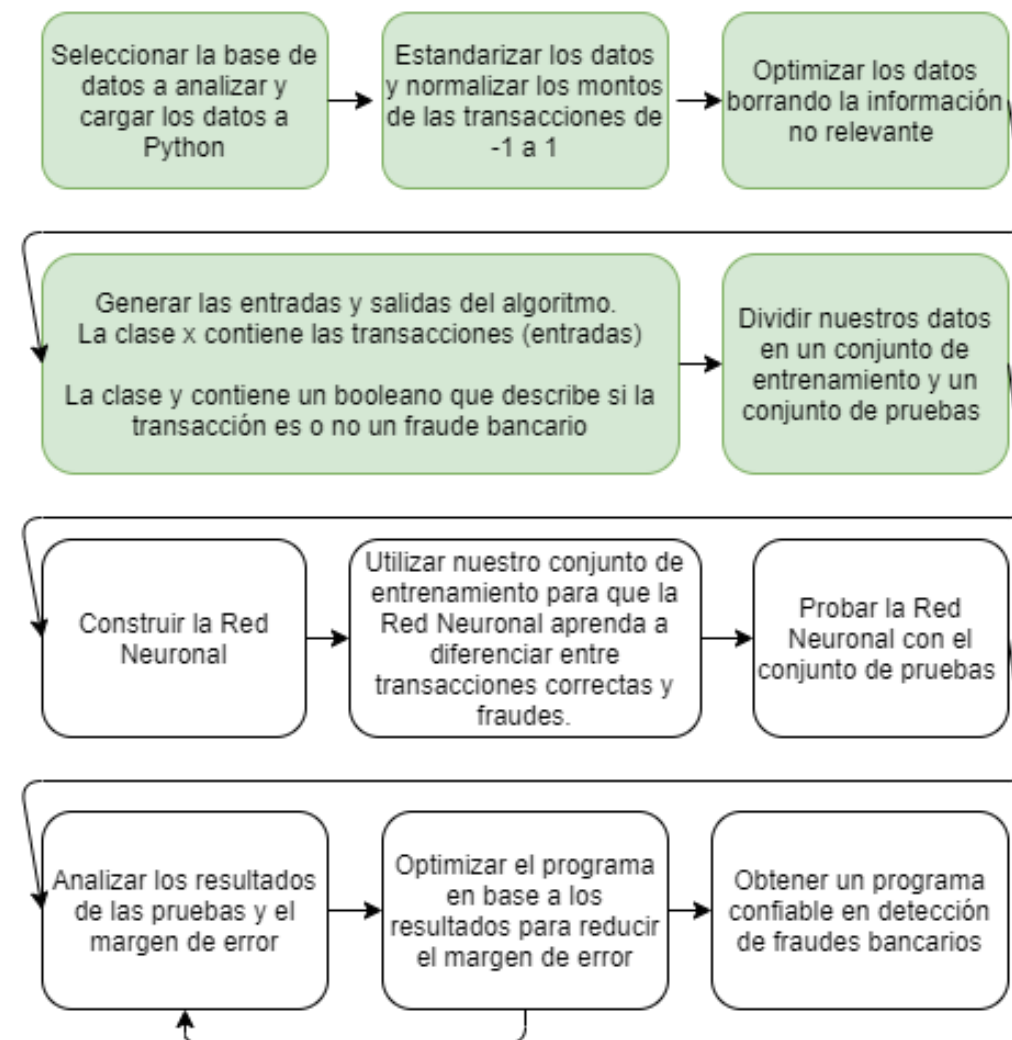
Sklearn



Tensorflow



Keras



Manejo de los datos

Análisis por PCA, Normalización y Optimización de los Datos

```
# Standardizacion de los datos del monto
scaler = preprocessing.StandardScaler()
# Normalizacion de los montos de -1 a 1
datos["NORMALIZADO"] = scaler.fit_transform(datos["Amount"\
].values.reshape(-1, 1))

# Borrar las columnas de tiempo y monto no normalizado
datos = datos.drop(["Amount", "Time"], axis = 1)
```

- 1 **PCA:** se seleccionan los datos relevantes para el análisis, se apoya en eigenvalores, eigenvectores, la covarianza y otras medidas estadísticas.
- 2 **Normalización:** se escalan los datos del monto de -1 a 1, manteniendo la relación entre ellos para evitar trabajar con números muy grandes.
- 3 **Optimización:** se eliminan aquellas columnas con datos que no se utilizan en el análisis.

Conjuntos de entrenamiento y pruebas para Machine Learning

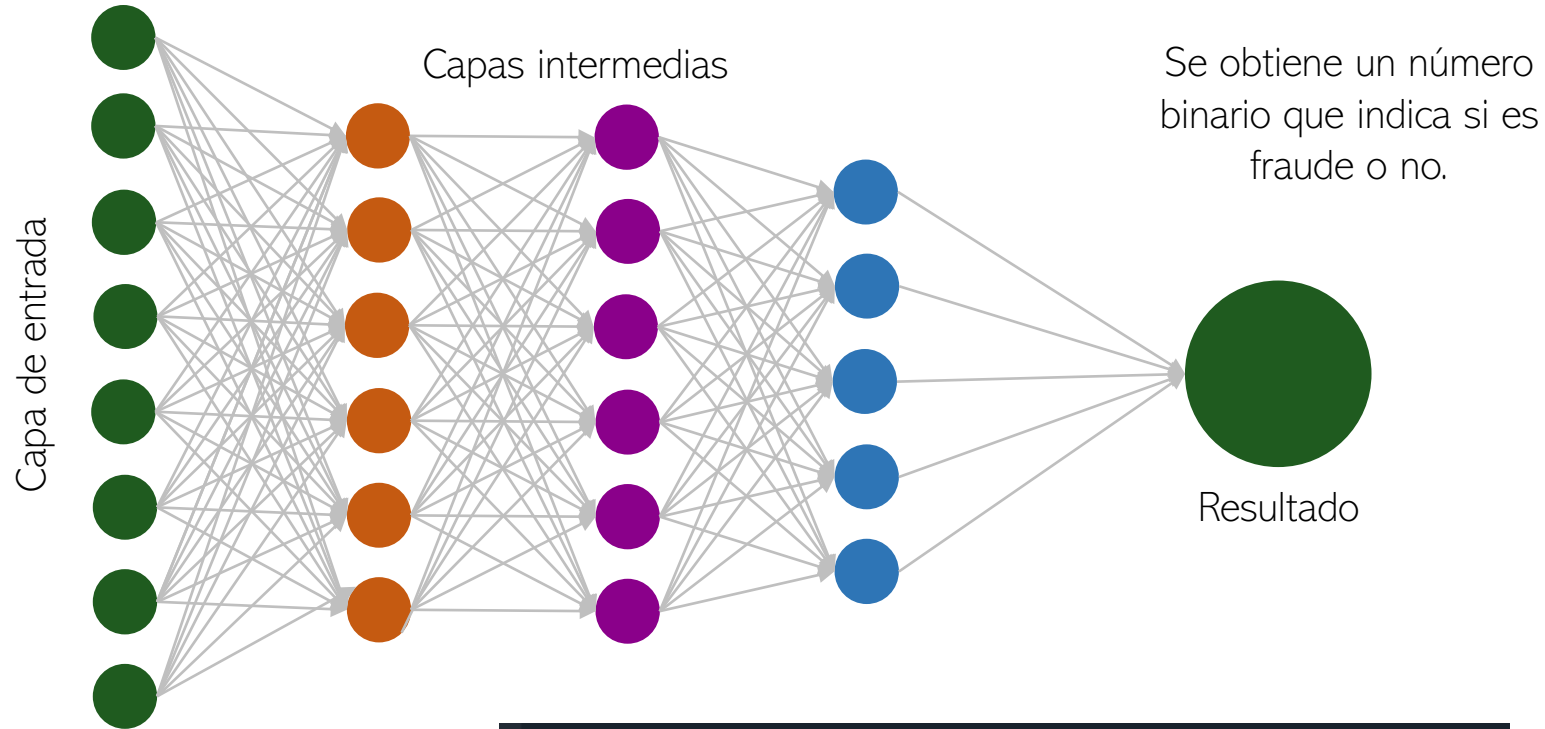
Clase X: contiene la información de las transacciones y el monto normalizado.

Clase Y: contiene un booleano que dice si es o no fraude bancario.

70% Entrenamiento

30% Pruebas

Red Neuronal Artificial



```
# Acreamos las capas de neuronas
modelo.add(layers.Dense(29, activation="relu", name = "capa1"))
modelo.add(layers.Dense(16, activation="relu", name = "capa2"))
modelo.add(layers.Dense(8, activation="relu", name = "capa3"))
modelo.add(layers.Dense(1, activation="sigmoid", name = "capa4"))
```

Cuatro Capas de Neuronas

Tamaño de Activación

Tamaño de la primera capa de neuronas, es el mismo que los datos de entrada.

Capa 1

Función de activación: relu. Tiene 29 neuronas.

Capa 2

Función de activación: relu. Tiene 16 neuronas.

Capa 3

Función de activación: relu. Tiene 8 neuronas.

Capa 4

Función de activación: sigmoid, nos da valores de 0 o 1. Tiene 1 neurona.

Funciones de Activación

- Activación Relu
- Activación Sigmoid

Construcción de la Red

Se utiliza el método de Adams para compilar la Red, este permite disminuir la gradiente cuando se entrena la neurona para aproximar mejor los resultados deseados.

```
Model: "sequential_68"
```

Layer (type)	Output Shape	Param #
capa1 (Dense)	multiple	870
capa2 (Dense)	multiple	480
capa3 (Dense)	multiple	136
capa4 (Dense)	multiple	9

Total params: 1,495
Trainable params: 1,495
Non-trainable params: 0

Entrenamiento de la Red

Se entrena la neurona con el 70% de los datos y se solicita que se realice el entrenamiento 5 veces para supervisar la disminución en el error y el aumento en la efectividad.

Epoch 1/5 60/60 [=====]	16s 266ms/step	loss: 0.5703	acc: 0.7202
Epoch 2/5 60/60 [=====]	5s 90ms/step	loss: 0.1256	acc: 0.9983
Epoch 3/5 60/60 [=====]	5s 77ms/step	loss: 0.0206	acc: 0.9983
Epoch 4/5 60/60 [=====]	5s 76ms/step	loss: 0.0067	acc: 0.9989
Epoch 5/5 60/60 [=====]	5s 82ms/step	loss: 0.0048	acc: 0.9992
	Tiempo	Error	Efectividad

```
▼ modelo.fit(X_train, Y_train, steps_per_epoch= 20, batch_size = 15, \  
epochs = 5, verbose=1)
```

- **Steps per epoch:** Iteraciones por etapa de entrenamiento.
- **Batch size:** Número de datos analizados en cada paso.
- **Epochs:** Etapa de entrenamiento actual.

Conclusiones

A

La red neuronal programada tiene un porcentaje de efectividad muy alto y un índice de error muy bajo, por lo que es un método de análisis de datos confiable.

B

Al analizar datos sensibles, como información bancaria, es imperativo tener certeza de que el algoritmo funciona bien para maximizar la detección de transacciones fraudulentas.



Resultados de la Red Neuronal Artificial

```
PROBAR LA RED NEURONAL-----  
1/1 [=====] - 28s 28s/step - loss: 0.0045 - acc: 0.9993  
El error es de: 0.004460305441170931  
La efectividad es de: 99.93%
```